Trident

Высокоуровневая абстракция поверх Storm

Зачем нужен Trident?

- Выше уровень абстракции по сравнению со storm
 - Потоки данных и функции
 - DSL (Domain specific language) для создания топологий
- Транзакционные топологии
- Сохранения состояния во внешних системах

Идея Trident

• Граф потоков данных задается с помощью dsl

```
Stream wordCounts = topology.newStream("spout1", spout)
          .parallelismHint(1).shuffle()
          .each(new Fields("line"), new SplitFunction(), new
Fields("word")).shuffle()
          .each(new Fields("word"), new ToUpperFunction(), new
Fields("upper word"))
          .each(new Fields("upper word"), new PrintFilter())
          .partitionBy(new Fields("upper word"))
          .partitionAggregate(new Fields("upper_word"), new
WordAggregator(), new Fields("counts"))
          .parallelismHint(10)
          .each(new Fields("counts"), new PartitionCountPrinter(), new Fields()
          );
```

• Потоки данных trident компилируются в обычные топологии storm

Запуск локальной топологии Trident

```
TridentTopology topology = new TridentTopology();
Config conf = new Config();
conf.put(SimplePollSpout.POLL DIR, args[0]);
conf.put(SimplePollSpout.PROCESSED DIR,
args[1]);
LocalCluster cluster = new LocalCluster();
cluster.submitTopology("poll", conf, topology.build());
```

Trident Spout

- В Trident spout должен уметь генерировать tuple пакетами
- Базовый интерфейс Spout :

```
public interface IBatchSpout extends ITridentDataSource {
   void open(Map map, TopologyContext topologyContext);
   void emitBatch(long batchId, TridentCollector tridentCollector);
   void ack(long batchId);
   void close();
   Map getComponentConfiguration();
   Fields getOutputFields();
}
```

Koмaнды DSL .each

- Фильтрует поток данных Stream.each(Fields inputFields, Filter filter)
- Применяет функцию к потоку данных и генерирует дополнительные поля

Stream.each(Fields inputFields, Function function, Fields functionFields)

• Примеры

```
stream.each(
  new Fields("line"),
  new SplitFunction(),
  new Fields("word")
) ;
stream.each(new Fields("upper_word"), new PrintFilter())
```

Функции в .each

- Наследуем класс от BaseFunction
- Перегружаем методы prepare и execute

```
public static class SplitFunction extends BaseFunction {
    TridentOperationContext context;
     @Override
     public void prepare(Map conf, TridentOperationContext context) {
       this.context = context;
     @Override
     public void execute(TridentTuple objects, TridentCollector tridentCollector) {
       String s = (String) objects.get(0);
       String[] list = StringTools.splitAndRemoveNonSymbols(s);
       for (String word : list) {
         tridentCollector.emit(new Values(word));
```

Фильтры в .each

• Наследуем класс от BaseFilter public static class RegexpFilter extends BaseFilter { private String regexp; public RegexpFilter() { public RegexpFilter(String regexp) { this.regexp = regexp; @Override public boolean isKeep(TridentTuple objects) { String value = objects.getString(0); return value.matches(regexp);

Полное агрегирование .aggregate

- Применяет функцию аггрегирования ко всему потоку данных в рамках одного пакета данных batch
- Результат функции аггрегирования поступает в выходной поток данных
- В случае использования CombinerAggregator производится оптимизация аггрегации -
 - Trident создает дерево bolt которые паралеллельно производят аггрегацию
- В случае использования ReducerAggregator или Aggregator
 - Trident создает один болт который производит агрегацию всего потока
- Пример:

Пример CombinerAggregator

```
public static class WordCombiner implements CombinerAggregator<Map<String, Integer>> {
    public Map<String, Integer> init(TridentTuple objects) {
       HashMap<String, Integer> result = Maps.newHashMap();
       String word = objects.getString(0);
       result.put(word, 1);
       return result;
    public Map<String, Integer> combine(Map<String, Integer> map1, Map<String, Integer> map2) {
       Map<String, Integer> result = Maps.newHashMap();
       result.putAll(map1);
       for (String key: map2.keySet()) {
         Integer value = map2.get(key);
         if(value!=null) {
            Integer existValue = result.containsKey(key) ? result.get(key) : 0;
            result.put(key, existValue+value);
       return result;
    public Map<String, Integer> zero() {
       return Maps.newHashMap();
```

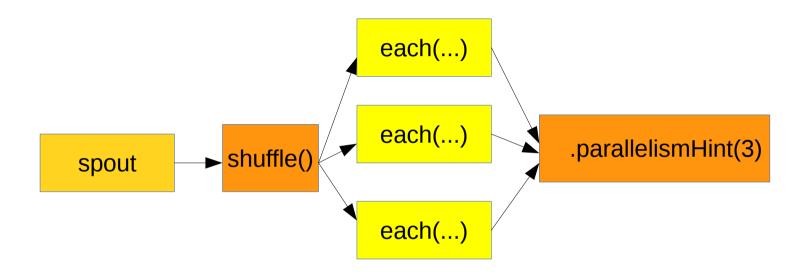
Пример BaseAggregator

```
public static class WordAggregator extends BaseAggregator<Map<String, Integer>> {
     @Override
    public Map<String, Integer> init(Object batchId, TridentCollector tridentCollector) {
       return new HashMap<String, Integer>();
     @Override
    public void aggregate(Map<String, Integer> stringIntegerMap,
                          TridentTuple objects, TridentCollector tridentCollector) {
       String word = objects.getString(0);
       Integer count = stringIntegerMap.get(word);
       count = count == null ? 1 : count + 1;
       stringIntegerMap.put(word, count);
     @Override
    public void complete(Map<String, Integer> stringIntegerMap, TridentCollector tridentCollector) {
       tridentCollector.emit(new Values(stringIntegerMap));
```

Партиционирование

- .shuffle() осуществляет случайное партиционирование
- .partitionBy(Fields fields) осуществляет партиционирование гарантируя одинаковому набору значений заданных полей попадание на один узел
- .parallelismHint(int hint) задает колчество параллельных потоков от этого места до предыдущей операции партиционирования

Примеры партиционирования



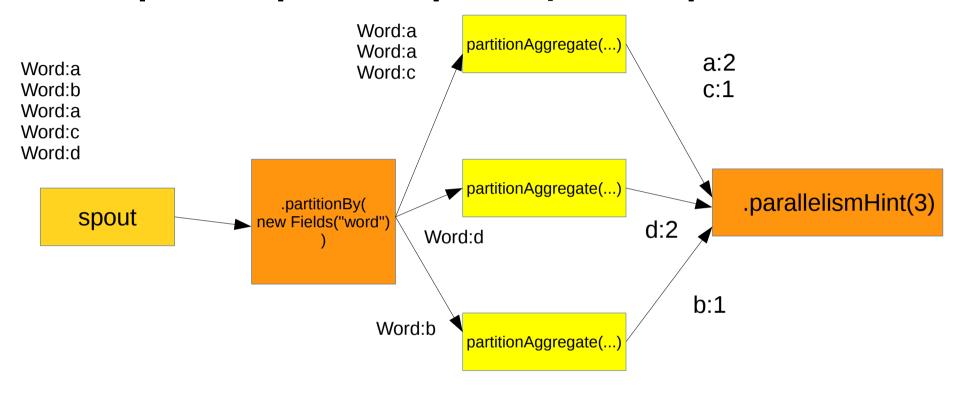
```
topology.newStream("spout1", spout)
.shuffle()
.each(new Fields("line"), new SplitFunction(), new Fields("word"))
.parallelismHint(3)
```

Агрегирование в рамках partition .partition Aggregate

- Аналогично полному аггрегированию, но производится параллельно и независимо в каждом partition
- Пример:

```
Stream wordCounts = topology.newStream("spout1", spout)
          .parallelismHint(1)
          .shuffle()
          .each(new Fields("line"), new SplitFunction(), new Fields("word")).parallelismHint(10)
          .shuffle()
          .each(new Fields("word"), new ToUpperFunction(), new Fields("upper_word"))
          .each(new Fields("upper word"), new PrintFilter())
          .partitionBy(new Fields("upper word"))
          .partitionAggregate(new Fields("upper word"),
                             new WordAggregator(), new Fields("counts"))
          .parallelismHint(10)
          .each(new Fields("counts"), new PartitionCountPrinter(), new Fields()
         );
```

Примеры партиционирования



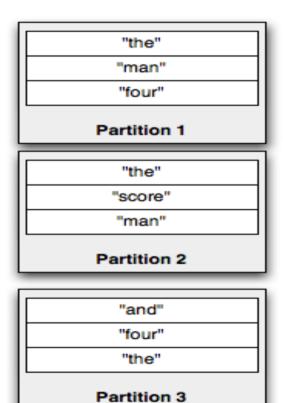
topology.newStream("spout1", spout)
.partitionBy(new Fields("Word"))
.partitionAggregate(new Fields("Word"), new WordAggregator(), new Fields("counts"))
.parallelismHint(3)

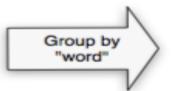
Группировка .groupBy

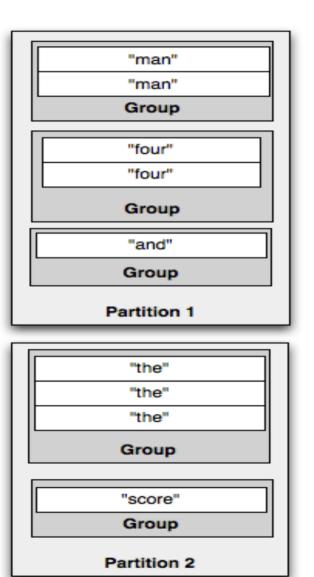
- Группировка отличается от партиционирования тем, что внутри partition сообщения дополнительно группируются по ключу
- Функция агрегирования будет вызываться не для всех сообщений в partition, а для каждого ключа отдельно

```
...
.groupBy(new Fields("upper_word"))
.aggregate(new Fields("upper_word"), new
WordAggregator(), new Fields("counts"))
```

groupBy



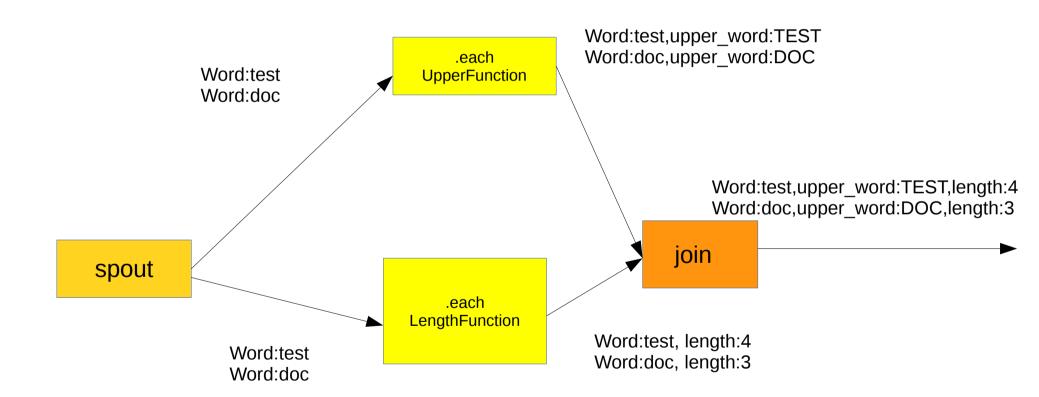




Join

- Связывает два потока данных по ключу
- Join осуществляется только в рамках одного пакета данных – batch
- В случае если потоки данных не порождены одним spout осуществляется координация spout join производится в рамках batch порожденных одним txid

Join



Пример Join

```
Stream stream1 = topology.newStream("spout1", spout)
          .parallelismHint(1)
          .shuffle()
          .each(new Fields("line"), new SplitFunction(), new Fields("word")).parallelismHint(10);
     Stream stream2 = stream1
          .shuffle()
          .each(new Fields("word"), new ToUpperFunction(), new Fields("upper word"))
          .project(new Fields("word", "upper word"));
     Stream stream3 = stream1
              .shuffle()
               .each(new Fields("word"), new SizeFunction(), new Fields("size"))
               .project(new Fields("word", "size"));
     Stream join = topology.join(stream2, new Fields("word"),
                      stream3, new Fields("word"),
                      new Fields("word", "upper word", "size")
         .each(new Fields("word", "upper word", "size"), new PrintAllFilter());
```